



YILDIZ TEKNİK ÜNİVERSİTESİ
KİMYA-METALÜRJİ FAKÜLTESİ
MATEMATİK MÜHENDİSLİĞİ BÖLÜMÜ

BİTİRME ÇALIŞMASI

MAKİNE ÖĞRENMESİ İLE DİYABET
TEŞHİSİNDE SINIF DENGESİZLİĞİ VE KARAR
EŞİĞİ OPTİMİZASYONU

Tez Yöneticisi: Prof. Dr. Fatih Taşçı

22052088 Damla Hilal Erden

İstanbul 2026

İÇİNDEKİLER


Sayfa

KISALTMA LİSTESİ	iii
ŞEKİL LİSTESİ	iv
TABLO LİSTESİ	viii
ÖNSÖZ	xi
ÖZET	xi
ABSTRACT	xii
1. GİRİŞ	1
2. MATERYAL VE METOT	3
2.1. Veri Seti ve Değişkenler	3
2.2. Veri Ön İşleme	5
2.3. Veri Bölünmesi	7
2.4. Veri Ölçekleme	8
2.5. Sınıf Dengeleme.....	9
2.6. İç İç Çapraz Doğrulama.....	10
2.7. Model Değerlendirme Yöntemleri ve Performans Metrikleri.....	11
3. SINIFLANDIRMA ALGORİTMALARI	12
3.1. Lojistik Regresyon Algoritması.....	12
3.2. K-En Yakın Komşu Algoritması.....	13
3.3. Karar Ağaçları	13
3.4. Rastgele Orman Algoritması.....	14
3.5. Katmanlı Topluluk Öğrenmesi.....	14
4. BULDULAR VE TARTIŞMA	15
4.1. Nihai Model Karşılaştırma ve Raporlama.....	15
4.1.1. Karşılaştırmalı Klinik Analiz.....	16
4.2. Olasılık Kalibrasyon Analizi ve Karar Eşiği Optimizasyonu.....	18
4.3. Model Açıklanabilirliği ve SHAP Analiz.....	20
5. SONUÇ VE DEĞERLENDİRME	23
5.1. Geleceğe Yönelik Çalışmalar.....	24
KAYNAKLAR	25
ÖZGEÇMİŞ	28


KISALTMA LİSTESİ

AUC	Area Under Curve (Eğri Altında Kalan Alan)
ROC	Receiver Operating Characteristic (Alıcı İşletim Karakteristiği)
KNN	K-En Yakın Komşu (K-Nearest Neighbor)
LR	Lojistik Regresyon
BMI	Body Mass Index (Vücut Kitle İndeksi)
DPF	Diabetes Pedigree Function (Diyabet Soyağacı Fonksiyonu)
IQR	Interquartile Range (Çeyrekler Açıklığı)
SMOTE	Synthetic Minority Over-sampling Technique (Sentetik Azınlık Aşırı Örneklememe Tekniği)
SHAP	Shapley Additive exPlanations (Shapley Katkısal Açıklamaları)
TURDEP	Türkiye Diyabet Epidemiyolojisi Çalışması
ADAP	Adaptive Neural Network (Uyarlanabilir Yapay Sinir Ağı)
CDSS	Clinical Decision Support Systems (Klinik Karar Destek Sistemleri)
CART	Classification and Regression Trees (Sınıflandırma ve Regresyon Ağaçları)
FN	False Negative (Yanlış Negatif)
FP	False_Positive (Yanlış Pozitif)
TN	True Negative (Doğru Negatif)
TP	True Positive (Doğru Pozitif)
NIDDK	National Institute of Diabetes and Digestive and Kidney Diseases (Ulusal Diyabet, Sindirim ve Böbrek Hastalıkları Enstitüsü)
XAI	Explainable Artificial Intelligence (Açıklanabilir Yapay Zekâ)


ŞEKİL LİSTESİ




Şekil 2.1.1 Outcome sınıf dağılımı




Şekil 2.2.1 Seçilen değişkenlerin hedef değişkene göre dağılımları




Şekil 2.3.1 Eğitim ve test seti sınıf dağılımı




Şekil 2.5.1 Smote öncesi ve sonrası sınıf dağılımı grafiği




Şekil 4.1.1 Modellerin f1 skorlarına göre karşılaştırmalı analizi




Şekil 4.2.1 Modellerin tahmin güvenilirliği ve kalibrasyon eğrisi karşılaştırması



Şekil 4.2.2 Modellerin precision-recall eğrileri ve klinik hataların seyri



Şekil 4.3.1 Klinik özelliklerin diyabet teşhisine etki dağılımı



Şekil 4.3.2 Diyabet teşhisinde en önemli klinik faktörler

TABLO LİSTESİ

Tablo 2.1.1 Pima indians diyabet veri seti değişken yapısı ve tanımları

Column	Açıklama	Non-Null Count	Dtype
Pregnancies	Hamilelik sayısı	768 non-null	int64
Glucose	Plazma glikoz konsantrasyonu	768 non-null	int64
BloodPressure	Diyastolik kan basıncı (mm Hg)	768 non-null	int64
SkinThickness	Triseps deri kalınlığı (mm)	768 non-null	int64
Insulin	İnsulin değeri	768 non-null	int64
BMI	Vücut kitle indeksi	768 non-null	float64
DiabetesPedigreeFunction (DPF)	Diyabet genetik yakınlık göstergesi	768 non-null	float64
Age	yaş	768 non-null	int64
Outcome	Hedef değişken (1: diyabetli, 0:sağlıklı)	768 non-null	int64

Tablo 2. 7.1 Model Değerlendirme Yöntemleri

Performans Ölçütleri	Açıklama	Matematiksel Formülü
Accuracy (Doğruluk)	Modelin doğru sınıflandırdığı örneklerin toplam örnek sayısına oranıdır.	$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$
Precision (Kesinlik)	Pozitif olarak tahmin edilen örneklerin ne kadarının gerçekten pozitif olduğunu gösterir.	$\text{Precision} = \frac{TP}{TP + FP}$
Recall (Duyarlılık)	Gerçek pozitif örneklerin ne kadarının doğru tahmin edildiğini ifade eder.	$\text{Recall} = \frac{TP}{TP+FN}$
F1	Precision ve recall değerlerinin dengeli bir ölçüsünü veren harmonik ortalamadır.	$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$
AUC	Modelin sınıfları ayırt edebilme başarısını gösteren ROC eğrisi altında kalan alanı ifade eder.	$\text{AUC} = P(f(x_+) > f(x_-))$

Tablo 4.1.1 Seçilen sınıflandırma modellerine ait test kümesi performans sonuçları

Model	Accuracy	Precision	Recall	F1	AUC
Random Forest (max depth = 5) (Baseline)	0,7792	0,6724	0,7222	0,6964	0,8154
Balanced Logistic Regression (thr = 0.45) (Baseline)	0,7403	0,5972	0,7963	0,6825	0,8322
Balanced Logistic Regression (thr = 0.4) (Baseline)	0,7208	0,5696	0,8333	0,6767	0,8322

ÖNSÖZ

Bu çalışma, 2025–2026 Güz Yarıyılı kapsamında, Matematik Mühendisliği Bölümü Bitirme Çalışması dersi çerçevesinde hazırlanmıştır. Çalışmanın yürütülmesi sürecinde değerli bilgi ve yönlendirmeleriyle katkı sağlayan danışman hocama teşekkür ederim. Ayrıca eğitim hayatım boyunca desteğini esirgemeyen aileme ve arkadaşlarıma teşekkürlerimi sunarım.

ÖZET

Bu çalışmada, Pima Indians Diabetes veri seti kullanılarak bireylerin diyabet hastası olup olmadığını yüksek doğrulukla tahmin edebilen bir sistem geliştirilmiştir. Bu sistem geliştirilerek diyabet hastalığına önceden tanı konmasını sağlamak amaçlanmıştır. Veri ön işleme aşamasında, biyolojik olarak anlamsız sıfır değerleri barındıran öznitelikler eksik veri olarak ele alınmış ve medyan değerler ile doldurulmuştur. Veri setindeki gürültüyü azaltmak amacıyla İnsülin değişkenindeki uç değerler Winsorizasyon yöntemi ile üst sınırlandırılmıştır.

Sınıflandırma sürecinde Lojistik Regresyon, K-En Yakın Komşu (KNN), Karar Ağacı (Decision Tree), Rastgele Orman (Random Forest) ve Katmanlı Topluluk Öğrenmesi (Stacking Ensemble) algoritmaları eğitilmiştir. Veri setindeki sınıfsal dengesizlik problemini aşmak adına SMOTE (Synthetic Minority Over-sampling Technique) yöntemi ve sınıfsal cezalandırma ($\text{class_weight} = \text{balanced}$) tabanlı optimizasyon stratejileri denenmiştir. En yüksek genel doğruluğu ve varsayılan F1 başarısını ham veri üzerinde eğitilen Rastgele Orman modelinin verdiği gözlenmiştir.

Ancak klinik teşhis süreçlerinde yanlış negatif tahminlerin önemi göz önünde bulundurularak, hassas bir kesinlik-duyarlılık dengesi aranmış ve olasılık karar eşikleri (threshold) optimize edilmiştir. Yapılan performans ve klinik risk analizleri neticesinde, yüksek hasta yakalama gücü, F1 kararlılığı ve tablodaki en yüksek sınıfsal ayırım kabiliyeti olan AUC skoru ile Dengeli Lojistik Regresyon (Threshold = 0.45) algoritması Nihai Sınıflandırıcı Model olarak seçilmiştir. Modellerin ürettiği olasılık tahminlerinin güvenilirliği Kalibrasyon Eğrisi ve Brier Skoru analizleriyle doğrulanmıştır. Nihai modelin yorumlanabilirliğini artırmak amacıyla SHAP (Shapley Additive exPlanations) tabanlı yapay zekâ analizleri gerçekleştirilmiştir.

ABSTRACT

In this study, a system capable of predicting whether individuals are diabetic with high accuracy was developed using the Pima Indians Diabetes dataset. The system aims to enable the early diagnosis of diabetes mellitus. During the data preprocessing phase, attributes containing biologically meaningless zero values were treated as missing data and handled using median imputation. To reduce noise in the dataset, extreme values in the Insulin variable were bounded using the Winsorization method.

In the classification phase, Logistic Regression, K-Nearest Neighbors (KNN), Decision Tree, Random Forest, and Stacking Ensemble algorithms were trained. To address the class imbalance problem inherent in the dataset, the SMOTE (Synthetic Minority Over-sampling Technique) method and class-weight balanced penalty optimization strategies were evaluated. The Random Forest model trained on raw data yielded the highest overall accuracy and default F1-score performance.

However, considering the importance of false-negative predictions in clinical diagnosis processes, a sensitive precision-recall trade-off was sought, and probability decision thresholds were optimized. Following comprehensive performance and clinical risk analyses, the Balanced Logistic Regression (Threshold = 0.45) algorithm was selected as the Final Classifier Model due to its high patient-detection capability, F1-score stability, and the highest class discriminative power in the matrix with its AUC score. The reliability of the probability estimations generated by the models was verified using Reliability Curve and Brier Score analyses. To enhance the interpretability of the final model, SHAP (Shapley Additive exPlanations) based artificial intelligence analyses were conducted.

1. GİRİŞ

Diyabet, insülin hormonunun üretilmemesi veya vücutta etkili bir şekilde kullanılamaması sonucu ortaya çıkan, küresel ölçekte epidemiyolojik bir kriz haline gelmiş kronik bir metabolizma hastalığıdır. Dünya genelinde diyabetli birey sayısı 1990 yılında yaklaşık 200 milyon iken, 2021 yılı itibarıyla 800 milyonun üzerine çıkmıştır [1,10]. Türkiye'de de durum benzer bir ivme göstermektedir. TURDEP (Türkiye Diyabet Epidemiyolojisi Çalışması) sonuçlarına göre ülkemizde diyabetli hasta sayısı beklentilerin üzerine çıkarak erişkin nüfusta yüzde 13,7 seviyesini aşmıştır. Bu istatistikler, diyabetin hem küresel hem de ulusal düzeyde sağlık sistemleri üzerinde büyük bir yük oluşturduğunu ortaya koymaktadır. Hastalık zamanında kontrol altına alınmadığında; kalıcı körlük, akut organ yetmezlikleri, kardiyovasküler hasarlar, inme ve periferik nöropati gibi geri dönüşü olmayan ciddi komplikasyonlara yol açabilmektedir [1]. Bu bağlamda, diyabetin klinik semptomlar derinleşmeden önce erken teşhis edilmesi, komplikasyonların önlenmesi ve yaşam kalitesinin korunması açısından hayati bir önem taşımaktadır [4, 5].

Geleneksel klinik teşhis yöntemleri, laboratuvar bulgularının hekimler tarafından doğrusal, statik ve büyük ölçüde kişisel tecrübeye dayalı olarak yorumlanmasına dayanmaktadır. Ancak, tıp dünyasının dijitalleşmesiyle birlikte biriken çok boyutlu hasta verileri, veri odaklı tıbbın ve modern klinik karar destek sistemlerinin doğmasını zorunlu kılmıştır. Teşhis süreçlerinde glikoz konsantrasyonu, kan basıncı, vücut kitle indeksi (BMI), insülin seviyesi ve genetik yatkınlık (Diabetes Pedigree Function) gibi çok boyutlu parametrelerin birbiriyle olan doğrusal olmayan etkileşimlerini insan zihninin çıplak gözle veya geleneksel istatistiksel skorlamalarla analiz etmesi oldukça zordur. Klinik parametreler arasındaki fonksiyonel ilişkilerin biçimi önceden tam olarak bilinemediğinde ve bu değişkenler yüksek derecede karmaşık etkileşimler ile iç korelasyonlar barındırdığında, standart istatistiksel yaklaşımlar yetersiz kalabilmektedir [6]. Makine öğrenmesi algoritmaları ise bu karmaşık ve gizli örüntüleri yüksek boyutlu vektör uzaylarında haritalandırarak, çok sayıda değişken arasındaki korelasyonu eş zamanlı olarak öğrenebilmekte ve erken teşhiste hekimlerin karar mekanizmalarını güçlendiren objektif tahminler üretebilmektedir [2, 9].

Sağlık ve klinik karar destek sistemleri gibi insan hayatını doğrudan ilgilendiren kritik alanlarda, bir modelin sadece yüksek doğrulukla tahmin üretmesi yeterli olmamaktadır. Hekimlerin sisteme güven duyması ve modeli klinik olarak doğrulayabilmesi için tahmine dayalı analitik yaklaşımların entegre edilmesi gerekmektedir [4, 5]. Literatür incelendiğinde, diyabet tahminine yönelik olarak Lojistik Regresyon, Karar Ağaçları, Rastgele Orman, K-En Yakın Komşu ve çeşitli yapay zekâ modellerinin yaygın ve etkin bir şekilde kullanıldığı görülmektedir [2, 3]. Ancak, ham klinik veri kümeleri genellikle gerçek dünya problemlerinden kaynaklanan dengesiz sınıf dağılımları, eksik gözlemler ve gürültülü parametreler içermektedir. Bu nedenle, sadece temel sınıflandırma algoritmalarını çalıştırmak klinik evrende güvenilir sonuçlar üretmek için yeterli değildir.

Bu çalışmanın tek amacı Pima Indians Diabetes veri seti üzerinde yüksek genel doğruluk oranına sahip bir model geliřtirmek deęildir. Aynı zamanda veri dengesizlięi (imbalance), veri sızıntısı (data leakage), aşırı öğrenme (overfitting) ve model olasılıklarının klinik güvenilirlięi (probability calibration) gibi gerçek dünya tıbbi veri madencilięi problemlerine matematiksel mühendislik çözümleri üretmektir. Bu doğrultuda çalışmada, geleneksel sınıflandırma modellerinin yanı sıra sentetik veri türetme (SMOTE) [7], sınıfsal cezalandırma (class-weight balancing), karar eřięi optimizasyonu ve katmanlı topluluk öğrenmesi (Stacking Ensemble) yöntemleri birlikte kullanılmıştır. Modellerin karar mekanizmaları SHAP tabanlı açıklanabilir yapay zekâ yöntemleri kullanılarak analiz edilmiştir [8].

Çalışmanın izleyen bölümlerinde řu akış takip edilmiştir: İkinci bölümde kullanılan Pima Indians Diabetes veri setinin yapısal özellikleri, eksik ve aykırı veri optimizasyonları ile kurulan iç içe çapraz doğrulama (Nested Cross-Validation) mimarisi açıklanmıştır. Üçüncü bölümde karşılaştırılan sınıflandırma algoritmalarının matematiksel altyapıları tanıtılmıştır. Dördüncü bölümde elde edilen performans metrikleri, kesinlik-duyarlılık dengesi, olasılık kalibrasyon eğrileri ve SHAP küresel önem analizleri sunulmuştur. Son bölümde ise elde edilen bulgular ışığında genel bir değerlendirme yapılarak gelecek çalışmalara yönelik önerilerde bulunulmuştur.

2. MATERYAL VE METOT

Bu bölümde, çalışmada kullanılan veri seti tanıtılmış; veri analizi, veri temizleme ve veri ölçekleme adımları ayrıntılı olarak açıklanmıştır. Ayrıca veri seti eğitim ve test kümelerine ayrılarak modelleme sürecine hazırlanmış ve sınıflandırma modellerinin performansını değerlendirmek için kullanılan ölçütler kısaca tanıtılmıştır.


2.1. Veri Seti ve Değişkenler

Bu çalışmada, literatürde benchmark (altın standart) kabul edilen ve Ulusal Diyabet, Sindirim ve Böbrek Hastalıkları Enstitüsü tarafından paylaşılan "Pima Indians Diabetes" veri seti kullanılmıştır. Bu veri seti, literatürde ilk kez Smith ve arkadaşları (1988) tarafından ADAP öğrenme algoritmasının değerlendirilmesi amacıyla bilim dünyasına kazandırılmıştır [6]. Veri seti toplam 768 gözlem ve 8 bağımsız özellik ile 1 bağımlı hedef değişken (Outcome) olmak üzere 9 sütundan oluşmaktadır. Veri setindeki değişkenlerin yapısal özellikleri ve tıbbi açıklamaları Tablo 2.1.1'de özetlenmiştir.

Tablo 2.1.1 Pima indians diyabet veri seti değişken yapısı ve tanımları

Column	Açıklama	Non-Null Count	Dtype
Pregnancies	Hamilelik sayısı	768 non-null	int64
Glucose	Plazma glikoz konsantrasyonu	768 non-null	int64
BloodPressure	Diyastolik kan basıncı (mm Hg)	768 non-null	int64
SkinThickness	Triseps deri kalınlığı (mm)	768 non-null	int64
Insulin	İnsulin değeri	768 non-null	int64
BMI	Vücut kitle indeksi	768 non-null	float64
DiabetesPedigreeFunction (DPF)	Diyabet genetik yakınlık göstergesi	768 non-null	float64
Age	Yaş	768 non-null	int64
Outcome	Hedef değişken (1: diyabetli, 0: sağlıklı)	768 non-null	int64

Veri setinin genel şeması incelendiğinde ilk bakışta eksik (null) veri barındırmadığı görülmektedir. Ancak hedef değişkenin (Outcome) sınıfsal dağılımı incelendiğinde, 768 bireyin 500'ünün (%65,10) sağlıklı (0 sınıfı), 268'inin (%34,90) ise diyabet tanısı almış (1 sınıfı) bireylerden oluştuğu tespit edilmiştir. Bu durum, veri setinin asimetrik ve dengesiz (imbalanced) bir sınıf dağılımına sahip olduğunu göstermektedir [7]. Hedef değişkene ait frekans dağılımı Şekil 2.1.1'de sunulmuştur.



Şekil 2.1.1 Outcome sınıf dağılımı


Veri kümesi üzerinde yürütülen tanımlayıcı istatistiksel analizlerde; Glucose, BMI, SkinThickness ve BloodPressure gibi değişkenlerde biyolojik ve fizyolojik olarak canlı bir insanda 0 değerini alması imkânsız olan gözlemler saptanmıştır. Veri madenciliği literatüründe bu tür sistemsel veya operasyonel hatalardan kaynaklanan sıfırlar, doğrudan eksik veri (missing data) olarak kabul edilmektedir. Bu verilere medyan imputasyonu uygulanmıştır [11, 12].

Öte yandan Insulin değişkeninde 374 adet (%48,70) sıfır değeri bulunmaktadır ve dağılım aşırı sağa çarpık bir karakter sergilemektedir.

Ayrıca, değişkenlerin varyans yapılarını incelemek amacıyla yürütülen Çeyrekler Açıklığı (IQR) analizlerinde [13], Insulin ve Diabetes Pedigree Function (DPF) değişkenlerinde istatistiksel olarak anlamlı uç değerler (outliers) gözlenmiştir. DPF sütunundaki uç değerlerin bireysel/etnik genetik varyasyonları ve kalıtsal çeşitliliği temsil ettiği düşünülerek orijinal halleriyle korunmasına karar verilmiştir. Buna karşılık, Insulin sütunundaki aşırı uç değerlerin ve gürültünün modelin gradyan kararlılığını bozmaması ve aşırı öğrenmeye (overfitting) yol açmaması adına Winsorizasyon (Winsorization) yöntemi uygulanmıştır [14].

2.2. Veri Ön İşleme

Modelleme aşamasına geçilmeden önce veri setindeki bağımsız değişkenlerin yapısal dağılımları, çoklu varyans durumları ve hedef değişken (Outcome) ile olan ilişkileri detaylı olarak incelenmiştir. Şekil 2.2.1’de, Glucose, BMI, Age ve Insulin değişkenlerinin diyabet durumuna (0: Sağlıklı, 1: Diyabetik) göre dağılımları kutu grafikleri (boxplot) ile gösterilmektedir.



Şekil 2.2.1 Seçilen değişkenlerin hedef değişkene göre dağılımları

Sürekli Değişkenlerin Hedef Değişkene (Outcome) Göre Dağılımları Şekil 2.2.1'deki kutu grafikleri analiz edildiğinde şu temel bulgulara ulaşılmıştır:

Glucose değişkeninde, diyabetik bireylerin (1 sınıfı) medyan değerinin (~140 mg/dL), sağlıklı bireylerin (0 sınıfı) medyan değerine (~107 mg/dL) kıyasla belirgin şekilde yüksek olduğu ve dağılım kutularının kartiller (çeyreklikler) düzeyinde neredeyse hiç çakışmadığı görülmektedir. Bu durum, glikoz değişkeninin sınıflandırma algoritmaları için ayırt edici gücü en yüksek özniteliklerden biri olduğunu göstermektedir [2].

BMI (Vücut Kitle İndeksi) ve Age (Yaş) dağılımlarında da diyabetik popülasyonun medyan ve varyans yayılımı daha yukarıda konumlanmaktadır. Özellikle yaş değişkeninde sağlıklı bireylerin genç yaş gruplarında yoğunlaştığı, diyabetik bireylerde ise dağılımın daha olgun yaşlara doğru genişlediği gözlenmiştir [4].

Insulin grafiği incelendiğinde, her iki sınıfta da alt kartillere yakın bölgelerde yoğun yığılmalar ve yukarı doğru uzanan çok sayıda uç değer (outlier) saptanmıştır. Geçersiz sıfır (0) değerleri, verinin genel dağılımını etkilememesi adına işleme tabi tutulmuştur.

Glucose, BMI ve BloodPressure değişkenlerinde biyolojik olarak mümkün olmayan sıfır değerler eksik veri olarak değerlendirilmiş ve medyan değerleri ile doldurulmuştur [11].


Insulin değişkeninde ise hem geçersiz sıfırların oranının çok yüksek olması (%48,70) hem de dağılımın yapısal olarak aşırı sağa çarpık bir karakter sergilemesi sebebiyle geçersiz sıfır verileri medyan ile doldurulmuştur. Çeyrekler Açıklığı (IQR) sınırlarının çok üzerinde kalan aşırı uç değerlerin aşırı öğrenmeye (overfitting) ve model kararsızlığına yol açmasını önlemek amacıyla üstten %1'lik kırpma içeren Winsorizasyon yöntemi uygulanmıştır [13, 14]. Bu işlem neticesinde, tüm uç değerler varyans kararlılığını sağlamak adına 400 üst tavan sınırına çekilerek normalize edilmiştir

Diabetes Pedigree Function (DPF) değişkeninde gözlenen yüksek değerler ise, insülinin aksine, sistemsal bir gürültü veya uç değer sızıntısı olarak değil; bireylerin ailevi ve kalıtsal genetik yatkınlıklarının biyolojik varyasyonu olarak değerlendirilmiş ve özgün yapısına müdahale edilmemiştir [6]. Ön işleme ve veri temizliği adımları tamamlanan veri seti, ölçekleme ve modelleme adımlarında kullanmak amacıyla kaydedilmiştir.

2.3. Veri bölünmesi

Modelleme sürecinin objektif bir şekilde değerlendirilmesi, ayrıca geliştirilen algoritmaların hiç görmediği yeni veriler üzerindeki genelleme yeteneğinin ölçülmesi adına, temizlenmiş Pima Indians veri seti %80 eğitim (train) ve %20 test kümesi olmak üzere ikiye ayrılmıştır.

Hedef değişkenin (Outcome) %65,10'a %34,90 olan asimetrik yapısının bozulmasını önlemek amacıyla basit rastgele bölme yerine, sınıf dağılımını koruyan “stratified sampling” yöntemi tercih edilmiştir [15]. Bu yöntem hem eğitim hem de test kümelerindeki hasta/sağlıklı oranının, orijinal veri setindeki oranla birebir aynı kalmasını sağlamaktadır.



Şekil 2.3.1 Eğitim ve test seti sınıf dağılımı

Veri bölünmesi sonucunda, orijinal veri setinde yer alan 768 gözlemden 614 tanesi (~%80) eğitim kümesine, geriye kalan 154 gözlem (~%20) ise test kümesine atanmıştır. Alt kümelere ait sınıfsal dağılım metrikleri şu şekildedir:

- **Eğitim Kümesi (N = 614):** 400 sağlıklı birey (%65,15) ve 214 diyabetik birey (%34,85) barındırmaktadır.
- **Test Kümesi (N = 154):** 100 sağlıklı birey (%64,93) ve 54 diyabetik birey (%35,07) barındırmaktadır.

Şekil 2.3.1’de görüldüğü üzere, her iki bağımsız kümedeki diyabetik birey oranı ~%35 seviyesinde sabit tutularak homojen bir deneysel zemin hazırlanmıştır. SMOTE sadece eğitim kümesi üzerinde uygulanmıştır. Test kümesi yalnızca modelin performansını ölçmek amacıyla saklanmış ve model geliştirme sürecinde hiçbir şekilde kullanılmamıştır. Bu durum, veri madenciliğinde karşılaşılan en büyük hatalardan biri olan veri sızıntısı (data leakage) riskini önemli oranda azaltmıştır [16, 17].

2.4. Veri Ölçekleme

Makine öğrenmesi algoritmalarının birçoğu, değişkenlerin sayısal büyüklüklerinden ve ölçüm birimlerinden doğrudan etkilenmektedir. Özellikle K-En Yakın Komşu (KNN) gibi mesafe tabanlı algoritmalar ile Lojistik Regresyon gibi gradyan inişi (gradient descent) kullanan doğrusal modellerde, farklı varyans ve ölçek aralıklarına sahip değişkenler nesnel ağırlık yönetimini olumsuz etkileyebilmektedir [18].

Bu matematiksel hatanın ölçek farklılıklarından kaynaklanan dengesizlikleri önlemek amacıyla modelleme aşamasından önce tüm sürekli sayısal değişkenlere “Standardization (Standartlaştırma)” işlemi uygulanmıştır. Bu çalışmada ölçekleme mimarisi olarak “StandardScaler” yöntemi tercih edilmiştir. StandardScaler algoritması, eğitim verisinin dağılımına göre, ortalamasını 0 ve standart sapmasını 1 olacak şekilde merkezi bir normal dağılıma dönüştürür. Dönüşümün matematiksel ifadesi şu formülle gerçekleştirilmektedir:

$$z = \frac{x - \mu}{\sigma} \quad (2.4.1)$$

Burada x orijinal öznitelik değerini, μ ilgili özneliğin eğitim kümesindeki aritmetik ortalamasını, σ standart sapmasını ve z ise standardize edilmiş yeni öznitelik skorunu (Z-skoru) temsil etmektedir.


Ölçekleme parametreleri olan μ (ortalama) ve σ (standart sapma) değerleri yalnızca eğitim kümesi (Train Set) üzerinden öğrenilmiştir. Test verisinin kendi istatistiksel parametrelerinin hesaplanmaması, modele anlık gelecek olan yeni hastaların verilerinin nasıl işleneceğini simüle etmekte ve veri sızıntısı (data leakage) riskini önlemektedir [16].

Dönüşüm öncesi ve sonrası yapılan karşılaştırmalı dağılım analizlerinde, tüm değişkenlerin yaklaşık olarak sıfır merkezli dağılıma dönüştüğü gözlemlenmiştir [19]. Bu sayede özellikle Lojistik Regresyon modelinin katsayı tahminleri ve KNN algoritmasının komşuluk mesafeleri matematiksel olarak kararlı ve güvenilir hale getirilmiştir.

2.5. Sınıf Dengeleme

Pima Indians Diabetes veri setinin hedef değişken (Outcome) dağılımı incelendiğinde; sağlıklı bireylerin (%65,10), diyabetik bireylere (%34,90) oranla belirgin bir popülasyon üstünlüğüne sahip olduğu görülmüştür. Makine öğrenmesi literatüründe bu durum "sınıf dengesizliği" (class imbalance) problemi olarak adlandırılır. Sınıf dengesizliği barındıran veri setlerinde algoritmalar, hata fonksiyonlarını (loss function) minimize etmek adına çoğunluk sınıfını (0 sınıfı) öğrenmeye eğilim gösterir ve bir yanlılık (bias) geliştirir. Bu durum, klinik açıdan asıl tespiti kritik olan azınlık sınıfına (1 sınıfı: diyabetik hastalar) ait gözlemlerin ıskalanmasına, yani modelin duyarlılık (recall) performansının düşmesine neden olabilir [7].

Bu çalışmada, söz konusu dengesizliği eğitim aşamasında ortadan kaldırmak amacıyla rastgele örnek kopyalama (Random Over-sampling) yöntemi yerine, SMOTE (Synthetic Minority Over-sampling Technique) algoritması kullanılmıştır. Rastgele veri kopyalama yöntemi veri setinde aynı örneklerin tekrarlanmasına ve dolayısıyla aşırı öğrenmeye (overfitting) yol açarken; SMOTE, azınlık sınıfına ait öznelilik ilişkilerini koruyan sentetik örnekler üretilmiştir [20].



Şekil 2.5.1 Smote öncesi ve sonrası sınıf dağılımı grafiği

SMOTE algoritmasının matematiksel çalışma mekanizması şu adımlarla gerçekleştirilmiştir:

1. Azınlık sınıfına ait her bir veri noktası için, o noktanın öznelilik uzayındaki Öklid mesafesi hesaplanarak en yakın k -komşusu ($k=5$) belirlenir.
2. Bu 5 komşu arasından rastgele bir X_{nn} komşusu seçilir.
3. Orijinal veri noktası ile seçilen komşu arasındaki çizgi üzerinde, doğrusal interpolasyon (linear interpolation) formülü kullanılarak yeni bir sentetik örnek hesaplanır.

Burada lambda, [0, 1] aralığında rastgele üretilen bir değişkendir. Bu matematiksel operasyon sayesinde, modellerin sınıfları birbirinden ayırmak için çizdiği karar sınırının daha iyi öğrenilmesini sağlamıştır. Modelin azınlık sınıfını ayırt etme yeteneği (F1-Skoru ve Recall dengesi) optimize edilmiştir. Veri sızıntısı (data leakage) riskini önlemek adına SMOTE işlemi yalnızca eğitim setine (Train Set) uygulanmış, test setine (Test Set) dokunulmamıştır [16].

2.6. İç İç Çapraz Doğrulama

Küçük veya orta ölçekli veri kümelerinde (Pima Indians veri setinde olduğu gibi $N=768$) model performansının yalnızca tek bir eğitim test bölünmesiyle veya standart bir k-katlı çapraz doğrulama (k-fold Cross-Validation) ile ölçülmesi, yanıltıcı sonuçlara yol açabilir. Standart çapraz doğrulama yöntemlerinde hiperparametre ayarı ile modelin nihai performans değerlendirmesi aynı veri havuzunda gerçekleştiğinden, en iyi parametrelerin seçimi esnasında test setine bilgi sızması riski oluşabilir.

Bu çalışmada, model seçimi ile genel başarı değerlendirmesini birbirinden tamamen izole etmek ve objektif genelleme yeteneğini ölçmek amacıyla İç İç Çapraz Doğrulama (Nested Cross-Validation) mimarisi kurulmuştur [21]. Algoritmanın matematiksel ve operasyonel yapısı birbirine bütünleşmiş iki ana döngüden oluşmaktadır:

- **Dış Döngü (Outer Loop):** Bu döngü, modelin hiç görülmemiş veriler üzerindeki genelleme yeteneğini objektif olarak test etmekle görevlidir. Veri seti, dış döngü kapsamında 5-katlı çapraz doğrulamaya tabi tutulmuştur. Her adımda verinin %80'i model geliştirme, geriye kalan %20'si ise saf test için ayrılmıştır.
- **İç Döngü (Inner Loop):** Dış döngünün model geliştirme için ayırdığı %80'lik veri, kendi içinde tekrar 5-katlı bir iç döngüye sokulmaktadır. İç döngü, hiperparametre uzayını (örneğin Rastgele Orman için maksimum derinlik ve ağaç sayısı, KNN için komşuluk sayısı k) tarayarak en optimal parametre kombinasyonunu seçmektedir.

İç döngüde belirlenen en iyi parametreler, dış döngünün o adımdaki test seti üzerinde performans ölçümüne tabi tutulur. Bu süreç 5 kez tekrarlanarak modelin bias ve varyans dengesi en kararlı düzeye ulaştırılır.

Kurulan bu modelleme süreci sonucunda, dış döngü katmanlarından elde edilen Ortalama F1-Skoru: 0,8336 (artı/eksi 0,0282) olarak hesaplanmıştır. Standart sapma değerinin ($\sigma = 0,0282$) oldukça düşük olması, geliştirilen matematiksel modelin veri setindeki farklı alt örneklemelere karşı yüksek varyans göstermediğini, kararlı ve güvenilir bir genelleme başarısına ulaştığını göstermektedir.

2.7. Model Değerlendirme Yöntemleri ve Performans Metrikleri

Bu çalışmada model değerlendirme yöntemleri olarak doğruluk (accuracy), kesinlik (precision), duyarlılık (recall), F1-score, AUC metrikleri üzerinden karşılaştırılmıştır. Kullanılan performans ölçütleri Tablo 2.7.1’de özetlenmiştir. Bu ölçütler arasında F1-score ana değerlendirme metriği olarak kullanılmıştır [2, 22].

Tablo 2. 7.1 Model değerlendirme yöntemleri

Performans Ölçütleri	Açıklama	Matematiksel Formülü
Accuracy (Doğruluk)	Modelin doğru sınıflandırdığı örneklerin toplam örnek sayısına oranıdır.	$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$
Precision (Kesinlik)	Pozitif olarak tahmin edilen örneklerin ne kadarının gerçekten pozitif olduğunu gösterir.	$\text{Precision} = \frac{TP}{TP + FP}$
Recall (Duyarlılık)	Gerçek pozitif örneklerin ne kadarının doğru tahmin edildiğini ifade eder.	$\text{Recall} = \frac{TP}{TP+FN}$
F1	Precision ve recall değerlerinin dengeli bir ölçüsünü veren harmonik ortalamadır.	$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$
AUC	Modelin sınıfları ayırt edebilme başarısını gösteren ROC eğrisi altında kalan alanı ifade eder.	$\text{AUC} = P(f(x_+) > f(x_-))$

3. SINIFLANDIRMA ALGORİTMALARI

Bu çalışmada, diyabet teşhisi ve risk tahmini problemlerinin çözümü amacıyla farklı matematiksel ve istatistiksel altyapılara sahip makine öğrenmesi algoritmaları seçilmiştir. Süreç kapsamında parametrik, mesafe tabanlı, ağaç tabanlı ve topluluk öğrenmesi mimarilerini temsil eden Lojistik Regresyon, K-En Yakın Komşu, Karar Ağaçları, Rastgele Orman ve Katmanlı Topluluk Öğrenmesi modelleri kurulmuş, optimize edilmiş ve performansları karşılaştırılmıştır.

3.1. Lojistik Regresyon Algoritması

Lojistik Regresyon (LR), bağımlı değişkenin ikili (binary: 0 veya 1) olduğu sınıflandırma problemlerinde yaygın olarak kullanılan parametrik ve doğrusal bir yöntemdir [23]. Algoritma, bağımsız değişkenlerin doğrusal kombinasyonunu alır ve elde edilen ham skorları doğrusal olmayan Lojistik (Sigmoid) fonksiyonu aracılığıyla 0 ile 1 arasında değişen bir olasılık değerine dönüştürür. Sigmoid fonksiyonunun matematiksel ifadesi şu şekildedir:

$$\sigma(x) = \frac{1}{1+e^{-x}} \quad (3.1.1)$$

Hesaplanan $\sigma(x)$ olasılık değeri, bir gözlemin diyabet hastası olma ihtimalini gösterir. Standart Lojistik Regresyon modellerinde varsayılan karar eşiği (threshold) 0,50 olarak kabul edilir; yani olasılığı 0,50 ve üzerinde olan bireyler hasta, altında olanlar ise sağlıklı olarak sınıflandırılır.

Ancak tıp ve klinik teşhis alanında, yanlış negatiflerin (hasta birine sağlıklı denmesi) yaratacağı hayati risk, yanlış pozitiflerin yaratacağı maliyetten çok daha yüksektir. Bu doğrultuda çalışmada iki kritik işlem yapılmıştır. İlk olarak, veri setindeki sınıfsal asimetriyi dengelemek amacıyla modele "class_weight=balanced" parametresi entegre edilerek, azınlık sınıfı hatalarına optimizasyon esnasında daha yüksek ceza puanı verilmesi sağlanmıştır (Dengeli Lojistik Regresyon). İkinci olarak, 0.50 olan varsayılan karar eşiği yerine gözden kaçan hasta sayısını minimize eden "Eşik Optimizasyonu" (Threshold Optimization) uygulanmıştır.

3.2. K-En Yakın Komşu Algoritması

K-En Yakın Komşu (KNN) algoritması, herhangi bir parametrik model varsayımında bulunmayan, sınıflandırma işlemini doğrudan öznitelik uzayındaki geometrik yakınlıklara dayandıran mesafe tabanlı bir yöntemdir [24]. Test kümesinden gelen yeni bir hasta kaydının sınıfı, eğitim uzayında o noktaya en yakın olan k adet komşunun çoğunluk oyuna göre belirlenir. Mesafe ölçüm kriteri olarak, çok boyutlu uzayda iki nokta arasındaki doğrusal uzaklığı hesaplayan Öklid Mesafesi formülü kullanılmıştır.

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2} \quad (3.2.1)$$

Özelliklerin ham değer aralıkları (örneğin İnsülin ile DPF arasındaki yüzlerce katlık fark) mesafe hesaplamalarını doğrudan saptırabileceği için, KNN modellemesi öncesinde Bölüm 2.4'te detaylandırılan StandardScaler standardizasyonu uygulanmıştır [18]. Algoritmanın hiperparametre optimizasyonu kapsamında en uygun karmaşıklık düzeyini belirlemek adına farklı komşuluk sayıları ($k = 3, 5, 7, 9$) iç döngüde sınanmıştır. En dengeli sonuç veren k değeri seçilmiştir.

3.3. Karar Ağaçları

Karar Ağaçları, eğitim verisindeki öznitelikleri belirli matematiksel kurallara göre kökten yapraklara doğru dallara ayırarak hiyerarşik bir karar yapısı oluşturan bir algoritmadır [25]. Model, her bir bölünme adımında veriyi en saf alt kümelerle ayırmayı hedefler. Bu saflık derecesini ve bölünme kalitesini ölçmek amacıyla literatürde sıkça kullanılan Bilgi Kazancı (Information Gain) veya Gini İndeksi (Gini Impurity) kriterlerinden yararlanılır.

$$\text{Gini}(t) = 1 - \sum_{i=1}^c (p_i)^2 \quad (3.3.1)$$

Karar Ağaçları, doğası gereği eğitim verisine aşırı uyum sağlama ve ezberleme (overfitting) eğilimi yüksek olan modellerdir. Bu yapısal riskin analiz edilmesi ve kontrol altına alınması amacıyla, çalışmada ağacın büyüme sınırını belirleyen maksimum derinlik (max_depth) parametresi kontrollü olarak değiştirilmiştir. Farklı derinlik seviyelerinin modelin eğitim ve test varyansı üzerindeki etkileri incelenerek, ağacın budama (pruning) benzeri bir yaklaşımla optimum seviyede durdurulması sağlanmıştır.

3.4. Rastgele Orman Algoritması

Rastgele Orman algoritması, tek bir karar ağacının yüksek varyans ve ezberleme problemini çözmek amacıyla geliştirilmiş, birden fazla karar ağacının kolektif kararına dayanan güçlü bir topluluk (ensemble) öğrenmesi yöntemidir [26]. Algoritma, "Torbalama" (Bagging) ve "Öznitelik Alt Küme Seçimi" yöntemlerini bir arada kullanır. Ormandaki her bir ağaç, orijinal eğitim setinden rastgele seçilen farklı alt veri kümeleri ve yine rastgele seçilen öznitelik kombinasyonları üzerinde bağımsız olarak eğitilir.

Nihai sınıflandırma kararı, ormanda üretilen yüzlerce ağacın verdiği bireysel kararların çoğunluk oylamasıyla alınır. Bu varyasyon çeşitliliği, modelin genelleme yeteneğini ve gürültülü verilere karşı direncini tek bir karar ağacına kıyasla iyileştirir. Bu çalışmada, Rastgele Orman modeli farklı maksimum derinlik parametreleriyle test edilmiş ve ağaçların alt dallarında sınıf dengesizliğinden kaynaklı oluşabilecek yanlılığı engellemek adına "class_weight=balanced" stratejisiyle desteklenmiştir.

3.5. Katmanlı Topluluk Öğrenmesi

Sınıflandırma performansını tek bir algoritmanın matematiksel sınırlarından kurtarmak ve tahmin kararlılığını en üst düzeye çıkarmak amacıyla Katmanlı Topluluk Öğrenmesi (Stacking Ensemble) mimarisi tasarlanmıştır. Stacking, farklı öğrenme felsefelerine sahip modellerin tahmin güçlerini birleştiren ileri düzey bir kombinasyon tekniğidir. Geliştirilen iki aşamalı Stacking mimarisi şu şekilde kurgulanmıştır:

- **Birinci Katman (Temel Modeller / Base-learners):** Farklı uzaylarda ve farklı matematiksel mantıklarla çalışan Lojistik Regresyon, K-En Yakın Komşu ve Rastgele Orman modelleri paralel olarak eğitilmiştir. Bu sayede doğrusal ilişkiler (LR), mesafe ilişkileri (KNN) ve doğrusal olmayan kural ilişkileri (Random Forest) aynı anda yakalanmıştır. Temel modeller, test verileri için olasılık tahminleri üretmiştir.
- **İkinci Katman (Meta Model / Meta-learner):** Birinci katmandaki modellerin ürettiği bu olasılık tahminleri, ikinci katmanın girdisi (meta-features) olacak şekilde yeni bir matrise dönüştürülmüştür. Bu matris üzerinde, temel modellerin hangi durumlarda başarılı hangi durumlarda hataya meyilli olduğunu öğrenmek ve nihai kararı vermek üzere kararlı bir Lojistik Regresyon modeli konumlandırılmıştır.

Stacking mimarisinin temel felsefesi, bir modelin zayıflık gösterdiği veri bölgelerini, diğer modelin güçlü yönleriyle telafi ederek sistemin toplam varyansını ve yanlılığını eş zamanlı olarak düşürmektir.


4. BULGULAR VE TARTIŞMA

Bu bölümde; tezin önceki aşamalarında detaylandırılan veri ön işleme, sınıf dengeleme ve hiperparametre optimizasyonu süreçlerinin ardından elde edilen deneysel bulgular sunulmakta ve bu bulgular klinik öncelikler doğrultusunda tartışılmaktadır. Geliştirilen makine öğrenmesi modellerinin (Lojistik Regresyon, K-En Yakın Komşu, Karar Ağaçları, Rastgele Orman ve Katmanlı Topluluk Öğrenmesi) bağımsız test kümesi üzerindeki tahmin performansları analiz edilmiştir. Ayrıca, modellerin ürettiği risk skorlarının istatistiksel güvenilirliğini ölçmek adına yapılan olasılık kalibrasyonu analizlerine ve nihai modelin klinik karar mekanizmasını açıklayan yapay zekâ (XAI/SHAP) çıktılarına bu bölüm kapsamında yer verilmiştir.

4.1. Nihai Model Karşılaştırma ve Raporlama

Makine öğrenmesinde, tek bir algoritmanın sonucuna odaklanmak yerine farklı matematiksel yaklaşımlara (doğrusal, mesafe tabanlı, ağaç tabanlı ve topluluk öğrenmesi) sahip modelleri aynı veri kümesi üzerinde geliştirmek, veri kümesinin saklı örüntülerini en doğru şekilde yakalamanın temel koşuludur. Bu çalışmada, Pima Indians Diabetes veri seti üzerinde Lojistik Regresyon, K-En Yakın Komşu (KNN), Karar Ağaçları, Rastgele Orman (Random Forest) ve Katmanlı Topluluk Öğrenmesi (Stacking Ensemble) algoritmaları test edilmiştir.

Modellerin genel başarı seviyelerini, karmaşıklık düzeylerini ve hiperparametre optimizasyon süreçlerinin çıktılarını görebilmek adına, test kümesinden elde edilen F1-skorları üzerinden geniş ölçekli bir karşılaştırma analizi yürütülmüştür. Tüm modellerin F1-skorları Şekil 4.1.1'de sunulan karşılaştırmalı çubuk grafikte gösterilmiştir.



Şekil 4.1.1 Modellerin f1 skorlarına göre karşılaştırmalı analizi

Şekil 4.1.1 detaylı olarak incelendiğinde, veri setine uygulanan farklı ön işleme (Baseline vs SMOTE) ve farklı hiperparametre kombinasyonlarının modellerin kararlılığı üzerinde doğrudan belirleyici olduğu görülmektedir. Algoritmaların tekil performans metriklerini, hata matrisi bileşenlerini ve ayırım güçlerini sayısal olarak analiz edebilmek amacıyla ise Tablo 4.1.1'deki detaylı performans matrisi oluşturulmuştur. Bu doğrultuda, çalışmanın klinik önceliklerine en uygun olan en başarılı üç model Tablo 4.1.1'de raporlanmıştır.

Tablo 4.1.1 Seçilen sınıflandırma modellerine ait test kümesi performans sonuçları

Model	Accuracy	Precision	Recall	F1	AUC
Random Forest (max depth = 5) (Baseline)	0,7792	0,6724	0,7222	0,6964	0,8154
Balanced Logistic Regression (thr = 0.45) (Baseline)	0,7403	0,5972	0,7963	0,6825	0,8322
Balanced Logistic Regression (thr = 0.4) (Baseline)	0,7208	0,5696	0,8333	0,6767	0,8322

4.1.1. Karşılaştırmalı Klinik Analiz

Tablo 4.1.1 ve Şekil 4.1.1'den elde edilen çok boyutlu metrik matrisi klinik karar destek sistemlerinin tıbbi sorumlulukları ve risk öncelikleri açısından detaylıca analiz edilmiştir. Sağlık alanında veri odaklı teşhis modelleri kurulurken karşılaşılan en büyük sorun, algoritmaları sadece genel doğruluk oranına (Accuracy) odaklanarak değerlendirme eğilimidir [27]. Deneysel sonuçlar incelendiğinde, Random Forest (max depth = 5) (Baseline) modeli yüzde 77,92'lik genel doğruluk oranı ile tablodaki en yüksek skoru sergilemektedir.

Geniş bir bakış açısıyla bakıldığında, Random Forest modelinin Kesinlik (Precision) değeri yüzde 67,24, Duyarlılık (Recall) değeri yüzde 72,22 ve bu iki metriğin dengeli bir harmonik ortalaması olan F1-Skoru ise 0,6964 olarak hesaplanmıştır. Modelin 0,8154'lük AUC değeri de sınıfları ayırt etme kabiliyetinin oldukça güçlü olduğunu doğrulamaktadır. Bu doğrultuda Random Forest, ham parametreler ve varsayılan karar sınırları altında sistemin en yüksek F1 başarısına ulaşan algoritması olarak öne çıkmaktadır [26].

Ancak bir diyabet hastasının tespit edilemeyerek tedavi sürecinin geciktirilmesi hayati bir risk (Yanlış Negatif) taşımaktadır. Random Forest modelinin yüzde 72,22'lik Duyarlılık (Recall) oranı, test setindeki her 100 diyabet hastasından yaklaşık 28'inin model tarafından gözden kaçırılacağı anlamına gelmektedir. Klinik karar destek mekanizmalarında bu riski tolere edilebilir bir düzeye indirmek ve "hasta yakalama" başarısını olabildiğince maksimize etmek amacıyla, Lojistik Regresyon modeli üzerinde sınıfsal ağırlık dengelemesi (class_weight = balanced) uygulanmış ve olasılık karar eşikleri (threshold) optimize edilmiştir [28].

Bu optimizasyon süreci kapsamında karar eşiği 0,40 seviyesine çekildiğinde, Balanced Logistic Regression (thr = 0.4) (Baseline) modelinin Duyarlılık (Recall) değeri yüzde 83,33'e yükselerek veri setindeki en yüksek hasta tespit oranına ulaşmıştır. Ancak bu tanı senaryosunda, sağlıklı bireylere yanlışlıkla diyabet teşhisi konma oranı (Yanlış Pozitif) ciddi oranda artmıştır [29]. Buna bağlı olarak Kesinlik (Precision) değeri yüzde 56,96'ya gerilemiş ve F1-Skoru 0,6767 seviyesinde kalmıştır.


Karar eşiğinin 0,45 olarak belirlendiği Balanced Logistic Regression (thr = 0.45) (Baseline) modeli en ideal denge noktası olarak seçilmiştir [30]. Bu model varyasyonu, yüzde 79,63'lük Duyarlılık (Recall) değeriyle klinik olarak güvenli bir hasta yakalama gücü sunarken, Kesinlik (Precision) değerini yüzde 59,72 seviyesinde tutmaktadır. Modelin F1-Skoru 0,6825 ile optimize lojistik modeller arasındaki en yüksek kararlılığa ulaşırken, 0,8322'lik AUC skoru ise tablodaki tüm modeller arasındaki en yüksek sınıfsal ayırım gücünü temsil etmektedir [22].

Sonuç olarak; veri setinin ham dinamiklerinde en yüksek genel doğruluğu ve en yüksek F1 başarısını yakalayan algoritma Random Forest (max depth = 5) (Baseline) olmuştur. Ancak yanlış negatiflerin minimize edilmesi ve sınıfları birbirinden ayırt etme performansı (AUC) bir arada değerlendirildiğinde, karar eşiği değiştirilmiş olan Balanced Logistic Regression (Threshold = 0.45) (Baseline) modeli diğer modellere bakarak daha dengeli bulunmuştur [27]. Model seçimi yalnızca F1 veya Accuracy'ye göre değil, klinik analiz, olasılık kalibrasyonu ve karar eşiği esnekliği birlikte değerlendirilerek yapılmıştır. Modellerin ürettiği bu olasılık skorlarının güvenilirliği bir sonraki başlıkta kalibrasyon analizi ile incelenmiştir.

4.2. Olasılık Kalibrasyon Analizi ve Karar Eşiği Optimizasyonu

Makine öğrenmesi modellerinin tıbbi karar destek sistemlerinde kullanılabilmesi için sadece "hasta" veya "sağlıklı" şeklinde keskin sınıf tahminleri üretmesi yeterli değildir. Algoritmaların bu tahminleri üretirken arkada hesapladığı olasılık skorlarının (örneğin bir hasta için hesaplanan yüzde 80 diyabet riski) gerçek dünya ile ne kadar uyumlu olduğunu ölçmek, klinik güvenilirlik açısından önemlidir [31]. Bu doğrultuda, çalışmada eğitilen modellerin olasılık kalibrasyonlarını ölçmek adına istatistiksel bir metrik olan Brier Skoru hesaplanmıştır. Brier Skoru 0 ile 1 arasında değer almakta olup, 0 değerine yakınlık iyi bir kalibrasyon kalitesini ve gerçek hayata en yakın olasılık tahminlerini temsil etmektedir [32].

Modellerin olasılık tahmin güvenilirliklerini ve teorik mükemmellik çizgisinden sapmalarını görselleştirmek amacıyla Şekil 4.2.1'de sunulan Kalibrasyon Eğrisi analizi yürütülmüştür.




Şekil 4.2.1 Modellerin tahmin güvenilirliği ve kalibrasyon eğrisi karşılaştırması

Şekil 4.2.1'deki eğriler ve yapılan deneysel hesaplamalar incelendiğinde, Lojistik Regresyon modeli 0,1671'lik Brier Skoru ile güvenilir ve kararlı olasılık tahminleri üreten algoritma olmuştur.

Eğri detaylıca incelendiğinde, mavi çizginin kesikli gri renkli teorik mükemmellik çizgisine en yakın performansı sergilediği saptanmıştır. Sol üst panelde yer alan "Tahmin Yoğunluğu" histogramı ise modelin olasılık kümelenmelerini doğrulamaktadır. Buna karşılık, Katmanlı Topluluk Öğrenmesi (Stacking Ensemble) modeli ise kırmızı eğride görüldüğü üzere özellikle orta olasılık segmentlerinde teorik çizgiden sapmış ve 0,2087'lik Brier skorunda kalarak olasılık kalibrasyonu açısından daha zayıf bir performans sergilemiştir. Literatürde de sıklıkla vurgulandığı üzere, topluluk (ensemble) öğrenmesi mimarileri ve ağaç tabanlı karmaşık yapılar, karar sınırlarında taraflı olasılıklar üretmeye eğilimlidir ve bu durum tıbbi karar alma süreçlerinde yanıltıcı risk puanlarına yol açabilmektedir [33].

Modellerin kesinlik ve duyarlılık dengelerini dinamik olarak optimize etmek ve tıp dünyasındaki risk maliyetlerine göre en uygun karar sınırını belirlemek amacıyla Şekil 4.2.2'deki iki panelli optimizasyon grafiği oluşturulmuştur.




Şekil 4.2.2 Modellerin precision-recall eğrileri ve klinik hataların seyri

Şekil 4.2.2'nin sol panelinde yer alan "Modellerin Precision-Recall eğrileri ve Optimal Karar Noktaları", Lojistik Regresyon ve Stacking Ensemble modellerinin farklı eşik değerlerindeki davranışlarını göstermektedir. Yapılan optimizasyon neticesinde Lojistik Regresyon için optimal eşik değeri 0,36, Stacking Ensemble için ise 0,63 olarak işaretlenmiştir. Şekil 4.2.2'nin sağ panelinde yer alan "Eşik Değişimine Göre Klinik Hataların Ticari-Tıbbi Seyri" grafiği ise matematiksel optimizasyonun klinik gerekçesini doğrulamaktadır. Grafikte görüldüğü üzere, olasılık karar eşik değeri (Threshold) artırıldıkça, gözden kaçan hasta sayısı (Yanlış Negatif-FN) doğrusal olarak yükselmekte; buna karşın yanlış pozitif (FP) hızla azalmaktadır [34]. Klinik karar sistemlerinde bir diyabet hastasını gözden kaçırmamanın hayati riski, yanlış pozitiflerin maliyetinden çok daha yüksek olduğu için, bu iki eğrinin kesişim noktaları ve klinik ağırlıkları dikkate alınarak Balanced Logistic Regression için 0.45 karar eşiği denge noktası olarak seçilmiştir [28].


4.3. Model Açıklanabilirliği ve SHAP Analizi

Sınıflandırma modellerinin tıp dünyasında ve klinik karar destek sistemlerinde kabul görmesi için kararlarının matematiksel ve mantıksal olarak gerekçelendirilmesi gerekir. Bu çalışmada nihai üretim modeli olarak seçilen Dengeli Lojistik Regresyon (Balanced Logistic Regression) modelinin test kümesindeki her bir hastaya ait sınır kararlarını nasıl verdiğini ve klinik parametrelerin tahmini hangi yönde, ne kadar etkilediğini gözlemlemek adına açıklanabilir yapay zekâ (XAI) standartlarında olan SHAP analizi uygulanmıştır [8].

SHAP yöntemi, mikroekonomideki kooperatif oyun teorisi yöntemlerini (Shapley Değerleri) kullanarak her bir özneliğin (Glucose, BMI, Pregnancies vb.) diyabet risk tahmini üzerindeki katkısını hesaplamaktadır [35]. Modelin karar sınırlarını etkileyen faktörlerin yönünü ve yoğunluğunu gösteren SHAP öznelik etki dağılım grafiği Şekil 4.3.1'de, özelliklerin mutlak önem derecelerini gösteren grafik ise Şekil 4.3.2'de verilmiştir.



Şekil 4.3.1 Klinik özelliklerin diyabet teşhisine etki dağılımı



Şekil 4.3.2 Diyabet teşhisinde en önemli klinik faktörler

Şekil 4.3.1 ve Şekil 4.3.2'den elde edilen SHAP çıktıları birlikte analiz edildiğinde, Dengeli Lojistik Regresyon modelinin kararlarına en çok etki eden parametrenin Glucose değişkeni olduğu görülmüştür. Glikoz değişkeni, artı 0,93'lük SHAP ortalama değeriyle modelin tahmin gücüne en yüksek katkıyı sağlayan değişken olarak öne çıkmaktadır. Şekil 4.3.1'deki dağılım paneli incelendiğinde, yüksek glikoz seviyelerini temsil eden pembe ve kırmızı veri noktalarının sağ tarafta yoğunlaştığı görülmektedir. Bu durum, bireyin glikoz seviyesi yükseldikçe Lojistik Regresyon modelinin pozitif sınıfa (diyabet teşhisine) yönelme olasılığının arttığını göstermektedir.

Glikoz değişkenini sırasıyla BMI (Vücut Kitle İndeksi) ve Pregnancies (Gebelik Sayısı) öz nitelikleri takip etmektedir. BMI değişkeni artı 0,45'lik, gebelik sayısı ise artı 0,31'lik mutlak SHAP katkısıyla modelin karar mekanizmasındaki ikinci ve üçüncü en önemli sütunlar olarak öne çıkmaktadır. Şekil 4.3.1'de yüksek BMI ve yüksek gebelik sayısına ait kırmızı veri noktaları pozitif SHAP bölgesinde konumlanmıştır. Bu durumda bu faktörler diyabet eğilimini doğrudan artıran unsurlar olarak görülebilir.

Benzer şekilde Age (Yaş) değişkeni artı 0,22 ve Diabetes Pedigree Function (DPF / Diyabet Soyağacı Fonksiyonu) değişkeni artı 0,20 mutlak etkiyle modelin diyabet eğiliminde doğrusal olarak rol oynamaktadır. Yaş ilerledikçe ve ailedeki diyabet genetiği yoğunlaştıkça, diyabet olma riskinin arttığı görülmüştür.

Buna karşılık, BloodPressure (Kan Basıncı), Insulin (İnsülin) ve SkinThickness (Cilt Kalınlığı) değişkenlerinin mutlak SHAP değerleri sırasıyla artı 0,03, artı 0,02 ve artı 0,01 gibi oldukça düşük seviyelerde kalmıştır. Grafiklerde bu üç değişkene ait noktaların sıfır merkez çizgisi etrafında çok dar bir alanda sıkışması, bu parametrelerin nihai Lojistik Regresyon mimarisinde diyabet teşhisi üzerinde çok büyük bir etki yaratmadığını göstermektedir.

Sonuç olarak; doğrudan nihai model olan Balanced Logistic Regression üzerinden elde edilen bu matematiksel hiyerarşi, tıp literatüründeki klinik diyabet risk faktörleri ve epidemiyolojik bulgular ile uyum göstermektedir [36]. SHAP analizi ile yapılan bu değerlendirme, seçilen modelin sadece yüksek metrik başarısı üretmekle kalmadığını, aynı zamanda tıbbi gerçeklikle örtüşen, kararlı, açıklanabilir ve klinik olarak güvenilir kararlar verdiğini göstermektedir.

5. SONUÇ VE DEĞERLENDİRME

Bu çalışmada; dünya genelinde ve ülkemizde halk sağlığını tehdit eden en yaygın kronik hastalıklardan biri olan tip-2 diyabetin erken teşhisi ve risk tahmini amacıyla, literatürde benchmark kabul edilen "Pima Indians Diabetes" veri seti üzerinde bir veri bilimi ve makine öğrenmesi mimarisi kurgulanmıştır. Bu projede Lojistik Regresyon, K-En Yakın Komşu (KNN), Karar Ağaçları, Rastgele Orman (Random Forest) ve Katmanlı Topluluk Öğrenmesi (Stacking Ensemble) algoritmaları deneysel olarak kararlılık ve performans testlerine tabi tutulmuştur. Çalışma kapsamında elde edilen temel bulgular ve çıkarımlar şu şekildedir:

Veri Sızıntısının Engellenmesi: Klinik veri tabanlarında sıklıkla karşılaşılan veri sızıntısı (data leakage) ve aşırı iyimserlik (optimism bias) hatalarını engellemek adına, veri ön işleme, StandardScaler ölçekleme ve SMOTE sınıf dengeleme protokolleri sadece İç İç Çapraz Doğrulama (Nested Cross-Validation) mimarisinin eğitim döngülerinde çalıştırılmıştır. Test seti model süreçlerinden izole edilmiş, böylece modellerin gerçek dünya senaryolarındaki nesnel genelleme yetenekleri tam ve hatasız bir şekilde ölçülmüştür.

Klinik Risk ve Metrik Önceliklerinin Dengelenmesi: Sadece genel doğruluk (Accuracy) odaklı bir değerlendirmenin tıbbi teşhis süreçlerinde hatalara (Yanlış Negatif teşhisler) yol açabileceği görülmüştür. Yapılan testlerde Baseline Random Forest modeli %77,92 ile en yüksek genel doğruluğu üretmesine rağmen, diyabet hastalarını yakalama gücünü temsil eden Duyarlılık (Recall) oranının %72,22 seviyesinde kaldığı gözlenmiştir. Bu durum, her 100 hastadan 28'inin gözden kaçacağı anlamına gelmektedir.

Karar Eşiği Optimizasyonunun Başarısı: Tıbbi risk maliyetlerini asimetrik olarak dengelemek amacıyla yürütülen "Eşik Optimizasyonu" sonucunda, nihai model olarak belirlenen Dengeli Lojistik Regresyon modelinin karar sınırı 0,45 seviyesine çekilmiştir. Bu karar sınırı ile modelin Duyarlılık (Recall) değeri %79,63'e yükseltilmiş, sınıfları ayırt etme gücü (AUC: 0,8322) optimize edilmiş ve yanlış pozitifler minimum düzeyde tutularak uygun bir klinik denge noktası yakalanmıştır.

Olasılık Kalibrasyonu ve Güvenilirlik: Modellerin ürettiği risk puanlarının istatistiksel güvenilirliğini ölçmek adına yapılan Kalibrasyon Eğrisi (Reliability Curve) ve Brier Skoru analizlerinde, Lojistik Regresyon modelinin Stacking Ensemble modeline kıyasla teorik mükemmellik çizgisine daha yakın ve kararlı tahminler ürettiği görülmüştür.

SHAP ile Karar Doğrulama: SHAP analizi, modelin kararlarını matematiksel olarak gerekçelendirmesini sağlamıştır. Elde edilen SHAP analizinde diyabet riskini tetikleyen en baskın faktörlerin sırasıyla Glucose (Glikoz), BMI (Vücut Kitle İndeksi) ve Pregnancies (Gebelik Sayısı) olduğu görülmüştür. Bu matematiksel sıralama, tip literatüründeki bulgularla örtüşmektedir.

5.1. Geleceğe Yönelik Çalışmalar

Bu çalışmada kurulan analitik boru hattı (data pipeline), modüler yapısı sayesinde farklı kronik hastalıkların (kardiyovasküler hastalıklar, onkolojik risk analizleri vb.) tahmin süreçlerine de kolayca entegre edilebilecek esnekliktedir. Gelecekteki çalışmalarda, modelin zamana bağlı veri değişimlerine (data drift) karşı direncini artırmak adına daha geniş ve çok merkezli (multi-center) klinik veri havuzlarının sisteme dahil edilmesi planlanmaktadır. Ayrıca, SHAP tabanlı yerel açıklama (local explanation) arayüzleri geliştirilerek, hekimlerin poliklinik şartlarında anlık olarak kullanabileceği, hastaya özel risk gerekçelendirmesi sunan mobil veya web tabanlı bir Klinik Karar Destek Sistemi (CDSS) prototipinin hayata geçirilmesi hedeflenmektedir.

Sonuç olarak bu tez çalışması; mühendislik disiplininin veri işleme disiplini ve matematiksel optimizasyon yöntemlerini, tıp dünyasının öncelikleri ile birleştirerek, tip-2 diyabet teşhisinde güvenilir, açıklanabilir ve sürdürülebilir bir yapay zekâ modelinin kurulabileceğini göstermiştir.

KAYNAKLAR

- [1] World Health Organization, (2024), "Diabetes Fact Sheet", <https://www.who.int/news-room/fact-sheets/detail/diabetes> (Eriřim Tarihi: 04.01.2026).
- [2] Özlüer Bařer, B., Yangın, M., v.d. (2021), "Makine Öğrenmesi Teknikleriyle Diyabet Hastalığının Sınıflandırılması", *Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü Dergisi*, Cilt 25, Sayı 1, ss. 112-120.
- [3] Sulaeman, G., Nur, Y. S. R., et al. (2025), "Optimization of Extreme Learning Machine Models Using Metaheuristic Approaches for Diabetes Classification", *Journal of Teknik Informatika (JUTIF)*, cilt 6, sayı 3, ss. 1503–1516.
- [4] Alzboon, M. S., Alqaraleh, M., et al. (2025), "Diabetes Prediction and Management Using Machine Learning Approaches", *Data and Metadata*, cilt 4, makale no. 545.
- [5] Alam, M. A., Sohel, A., et al. (2024), "Machine Learning and Artificial Intelligence in Diabetes Prediction and Management: A Comprehensive Review of Models", *Journal of Next-Gen Engineering Systems*, cilt 1, sayı 1, ss. 107–124.
- [6] Smith, J. W., Everhart, J. E., et al. (1988), "Using the ADAP learning algorithm to forecast the onset of diabetes mellitus", *Proceedings of the Annual Symposium on Computer Application in Medical Care*, Los Angeles, CA: IEEE Computer Society Press, ss. 261-265.
- [7] Chawla, N. V., Bowyer, K. W., et al. (2002), "SMOTE: Synthetic Minority Over-sampling Technique", *Journal of Artificial Intelligence Research*, 16, ss. 321-357.
- [8] Lundberg, S. M., & Lee, S. I. (2017), "A Unified Approach to Interpreting Model Predictions", *Advances in Neural Information Processing Systems (NeurIPS 2017)*, 30, ss. 4765-4774.
- [9] Mujumdar, A., & Vaidehi, V. (2019), "Diabetes Prediction Using Machine Learning Algorithms", *Procedia Computer Science*, 165, ss. 292-299.
- [10] GBD 2021 Diabetes Collaborators, (2023), "Global, Regional, and National Burden of Diabetes from 1990 to 2021, with Projections of Prevalence to 2050: A Systematic Analysis for the Global Burden of Disease Study 2021", *The Lancet*, 402(10397), ss. 203-234.
- [11] Little, R. J., & Rubin, D. B. (2019), *Statistical Analysis with Missing Data*, John Wiley & Sons.
- [12] Rubin, D. B. (1976), "Inference and Missing Data", *Biometrika*, 63(3), ss. 581-592.

- [13] Tukey, J. W. (1977), *Exploratory Data Analysis*, Addison-Wesley.
- [14] Hastings, C., Mosteller, F., et al. (1947), “Low-Speed Enumeration of the Twentieth-to-Fortieth Percentiles of a Series”, *The Annals of Mathematical Statistics*, 18(3), ss. 413-426.
- [15] Kohavi, R. (1995), “A Study of Cross-Validation and Bootstrap for Accuracy Estimation and Model Selection”, *International Joint Conference on Artificial Intelligence (IJCAI)*, 14(2), ss. 1137-1145.
- [16] Kaufman, S., Rosset, S., et al. (2012), “Leakage in Data Mining: Formulation, Detection, and Avoidance”, *ACM Transactions on Knowledge Discovery from Data (TKDD)*, 6(4), ss. 1-21.
- [17] Kapoor, S., & Narayanan, A. (2023), “Leakage and the Reproducibility Crisis in Machine-Learning-Based Science”, *Patterns*, 4(9), ss. 100804.
- [18] Han, J., Pei, J., & Tong, H. (2022), *Data Mining: Concepts and Techniques*, Morgan Kaufmann.
- [19] Bishop, C. M., & Nasrabadi, N. M. (2006), *Pattern Recognition and Machine Learning*, Springer.
- [20] He, H., & Ma, Y. (2013), *Imbalanced Learning: Foundations, Algorithms, and Applications*, John Wiley & Sons.
- [21] Cawley, G. C., & Talbot, N. L. (2010), “On Over-Fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation”, *Journal of Machine Learning Research*, 11(70), ss. 2079-2107.
- [22] Fawcett, T. (2006), “An Introduction to ROC Analysis”, *Pattern Recognition Letters*, 27(8), ss. 861-874.
- [23] Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013), *Applied Logistic Regression*, John Wiley & Sons.
- [24] Cover, T., & Hart, P. (1967), “Nearest Neighbor Pattern Classification”, *IEEE Transactions on Information Theory*, 13(1), ss. 21-27.
- [25] Breiman, L., Friedman, J. H., et al. (2017), *Classification and Regression Trees*, Routledge.
- [26] Breiman, L. (2001), “Random Forests”, *Machine Learning*, 45, ss. 5-32.

- [27] Steyerberg, E. W., Vickers, A. J., et al. (2010), “Assessing the Performance of Prediction Models: A Framework for Traditional and Novel Measures”, *Epidemiology*, 21(1), ss. 128-138.
- [28] Elkan, C. (2001), “The Foundations of Cost-Sensitive Learning”, *International Joint Conference on Artificial Intelligence (IJCAI)*, 17(1), ss. 973-978.
- [29] Genders, T. S., Stimpson, R., & Hunink, M. M. (2012), “Evaluation of Clinical Prediction Models: A Review of Standard and Novel Performance Measures”, *Radiology*, 263(3), ss. 639-651.
- [30] Zou, K. H., O'Malley, A. J., & Mauri, L. (2007), “Receiver-Operating Characteristic Analysis for Medical Knowledge Discovery”, *Circulation*, 115(5), ss. 654-657.
- [31] Van Calster, B., McLernon, D. J., et al. (2019), “Calibration: The Achilles Heel of Predictive Analytics”, *BMC Medicine*, 17, ss. 1-7.
- [32] Brier, G. W. (1950), “Verification of Forecasts Expressed in Terms of Probability”, *Monthly Weather Review*, 78(1), ss. 1-3.
- [33] Niculescu-Mizil, A., & Caruana, R. (2005), “Predicting Good Probabilities with Supervised Learning”, *International Conference on Machine Learning (ICML)*, ss. 625-632.
- [34] Vickers, A. J., & Elkin, E. B. (2006), “Decision Curve Analysis: A Novel Method for Evaluating Prediction Models”, *Medical Decision Making*, 26(6), ss. 565-574.
- [35] Molnar, C. (2020), *Interpretable Machine Learning*, Lulu.com.
- [36] Ghassemi, M., Oakden-Rayner, L., et al. (2021), “The False Hope of Current Approach to Explainable AI in Healthcare”, *The Lancet Digital Health*, 3(11), ss. e745-e750.

ÖZGEÇMİŞ

Damla Hilal Erden, 2004 yılında İstanbul ilinde doğmuştur. Lise eğitimini Beşiktaş Atatürk Anadolu Lisesinde tamamlamıştır. 2022 yılında Yıldız Teknik Üniversitesi Matematik Mühendisliği Bölümünde lisans eğitimine başlamıştır. Lisans eğitimi süresince Bilgisayar Donanımı ve Temel Uygulamaları alanında zorunlu stajını tamamlamıştır. Bu çalışma, yazarın lisans öğrenimi kapsamında hazırladığı Bitirme Tezidir.